SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

ZAVRŠNI RAD br. 72

Praćenje magnetskog otiska mobilnim robotom

SVEUČILIŠTE U ZAGREBU
Fakultet elektrotehnike i računarstva

Gabrijel Biočić

Mentor: izv. prof. dr. sc. Matko Orsag

Zagreb, ožujak 2025.

SADRŽAJ

1. Uvod **v**

2. Korišteni hardver i softver **vi**

2.1. Hardver vi

2.1.1. Gradiometar vi

2.1.2. Mobilni robot vii

2.1.3. Neodimijski magneti i staza vii

2.1.4. Nastavak za gradiometar ix

2.2. Softver x

2.2.1. ROS x

2.2.2. PID kontroler x

3. Eksperimenti **xi**

3.1. Postav eksperimenta xi

3.1.1. Postavljanje gradiometra xi

3.2. ROS i PID xiv

3.2.1. Staza xiv

3.2.2. P regulator xiv

3.2.3. MAF i minimalna vrijednost xvii

4. Zaključak **xix**

5. Sažetak **xx**

Literatura **xxi**

1. Uvod

Navođenje mobilnih robota u prostoru moguće je izvesti različitim metodama. Jedna od pouzdanih metoda koja zahtjeva intervenciju u prostoru je praćenje linije kamerom na mobilnom robotu [2]. U ovom zadatku potrebno je izvesti ovaj kanonski problem upravljanja mobilnim robotom preko povratne veze temeljene na magnetskom polju. Potrebno je modificirati postojeći mobilni robot tako da ga se opremi senzorom za mjerenje magnetskog polja. Robot će morati pratiti kontinuiranu stazu sastavljenu od permanentnih magneta.
Krajnji cilj zadatka je riješiti problem praćenja magnetskog otiska. Rješavanje tog zadatka kasnije bi omogućilo primjenu i prilagodbu ovog rješenja na slične probleme. Neki od primjera bi bili označavanje stanice za punjenje magnetima, ograničavanje područja rada magnetima kao dodatna zaštita u navigiranju samog robota u ograničenom prostoru. Također prilikom vožnje snijeg ili bilo kakva druga slična prirodna pojava može omesti već postojeće sustave koji se oslanjaju na vidljive zapreke. Ti sustavi mogu se unaprijediti tako da se doda i sustav praćenja magnetskog polja te se doda zapreka magnetskom trakom, tako se sustav može navigirati iz više izvora [7].

2. Korišteni hardver i softver

2.1. Hardver

2.1.1. Gradiometar

Gradiometar je razvijen na Fakultetu elektrotehnike i računarstva u laboratoriju LARICS [6]. Za mjerenje magnetskog polja koristi SRIOD metodu koja osim iznosa magnetskog polja može mjeriti i orijentaciju. Podatke koji se dobiju sa senzora odgovaraju fizikalnoj veličini gustoće magnetskog polja. Mjerenja CTL i CTR se koriste kao ulaz u regulator. Ta mjerenja su dobivena s različitih pozicija na gradiometru te nam omogućuju orijentaciju u prostoru. Kako bi nam ti podaci bili korisni treba nam njihova razlika.

$$error_z = CTL - CTR \tag{2.1}$$

Razlika iz jednadžbe (2.1) može se koristiti kao pomak robota u odnosu magnetsko polje u lijevo ili desno ovisno o predznaku rezultata. Ta brojka se kasnije koristi za računanje potrebne brzine rotacije robota.

Senzor koristi UDP komunikaciju spojenu preko ethernet kabela na robotovo računalo. Prilikom postavljanja gradiometra važno je obratiti pažnju na smjer. Na njemu je

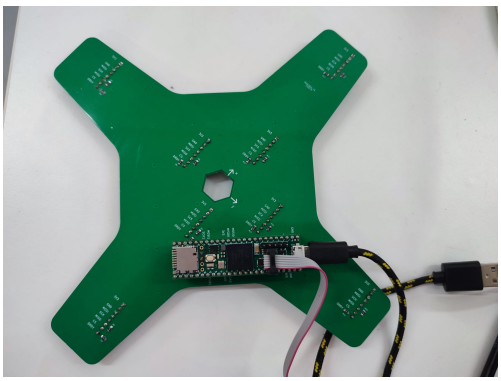

(a) Gornja strana s ugradbenim računalom.

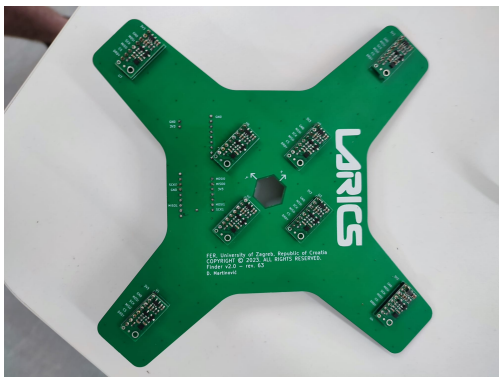

(b) Donja strana sa senzorima.

Slika 2.1: Gradiometar korišten u eksperimentima.

označen pozitivan smjer x i pozitivan smjer y. Algoritam razvijen u ovom radu pretpostavlja da se x os gradiometra postavlja u pozitivnom smjeru kretanja robota prema

naprijed. Osim navedenih CTL i CTR moguće je koristiti CTU i CTD što funkcionira na sličan način kao CTL i CTR. Razlika CTU i CTD nam govori koliko je izvor magnetskog polja udaljen po x osi. Prilikom eksperimenata postavljena je konstantna brzina prema naprijed te se koristi $error_z$ iz jednadžbe (2.1) za skretanje lijevo ili desno.

2.1.2. Mobilni robot

Robot koji se koristi za eksperimente je Scout Mini od Agile X Robotics [8]. Dimenzije mobilnog robota su $612 \times 580 \times 245$ mm, dok mu je masa 23 kg. Za komunikaciju koristi Standard can.232 serial port te ga je moguće kontrolirati preko cmd_vel topica u ROS-u. Prilikom izvođenja eksperimenata koristili su se omnidirekcionalni kotači.

Slika 2.2: Scout Mini robot s omnidirekcionalnim kotačima.

2.1.3. Neodimijski magneti i staza

Traka 2.4 koju robot prati složena je od niza paralelnih magneta koji čine stazu koju robot mora pratiti. Svaki par magneta je udaljen 5 centimetara od drugog para magneta. Magneti [5] su zalijepljeni za pod ljepljivom trakom 2.3a. Razlog korištenja neodimijskih magneta je njihova velika snaga te zbog toga mogu lakše nadjačati smetnje.

(a) Staza sa zaljepljenim neodimijskim magnetima.

(b) Neodimijski magneti.

Slika 2.3: Slike staze i magneta.

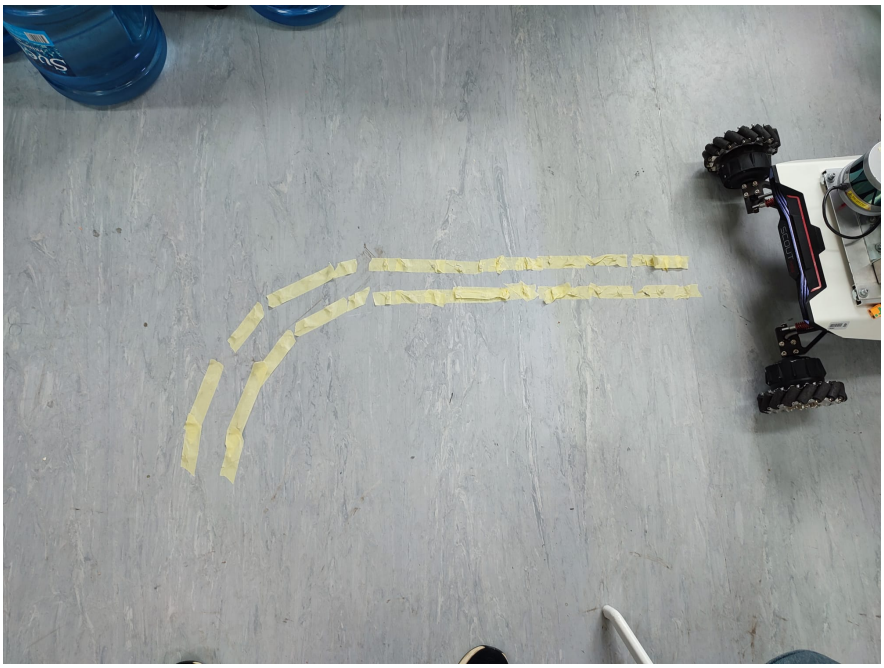

Slika 2.4: Staza s robotom

2.1.4. Nastavak za gradiometar

Gradiometar stoji ispod samoga robota te od tamo mjeri sve podatke. Kako bi on tamo stajao dizajniran je nastavak prikazan na Slici 2.5c na koji se senzor može staviti i učvrstiti. Modelirana su dva dijela. Nastavak koji se može staviti na robota te matica koja se stavlja na nastavak kako bi senzor ostao na mjestu [3]. Nastavci su dizajnirani u Autodesk Fusion 360 [1].

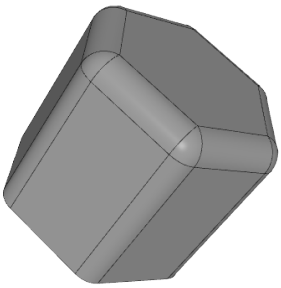

(a) Matica s vanjske strane.

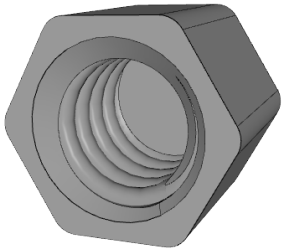

(b) Matica s unutarnje strane.

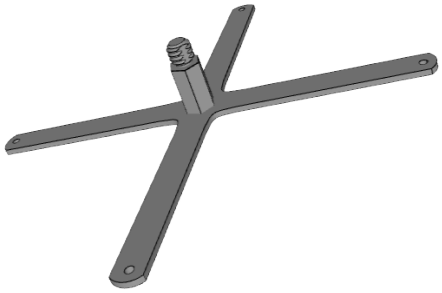

(c) Nastavak za gradiometar.

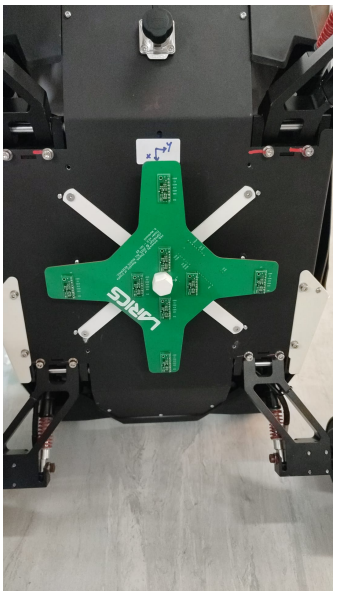

(d) Gradiometar na robotu.

Slika 2.5: Slike matice i nastavka za gradiometar.

2.2. Softver

2.2.1. ROS

Robotski operacijski sustav [4] je skup softverskih biblioteka koji služi kako bi se lakše izrađivalo aplikacije za upravljanje robotima. Omogućuje jednostavan način za implementaciju autonomnog načina rada. Korištena verzija ROS-a za ovaj projekt je ROS Noetic. Napisane su dvije skripte od kojih jedna šalje podatke sa senzora na ROS topic, te druga te podatke obrađuje i pretvara ih u cmd_vel. Za potrebe ovog projekta definiran je novi topic SRIOD_data na koji se šalju mjerenja senzora 2.1.1 pod nazivima CTU, CTD, CTR i CTL. S tog topica uzimaju se podatci koji se obrađuju i šalju na cmd_vel koji robot 2.1.2 prima te se kreće sukladno tim podatcima.

2.2.2. PID kontroler

PID (proporcionalni-integralni-derivacijski) kontroler je vrsta povratne veze koja se koristi u automatskoj regulaciji sustava kako bi se postigao željeni izlaz ili kontrola.

Proporcionalni dio regulatora (K_p) reagira na trenutnu vrijednost koju sustav dobiva u odnosu na željenu vrijednost. Što je veća greška do jače djeluje. Obično ima najveću vrijednost. Integracijski dio regulatora tijekom vremena akumulira pogrešku i koristi se za eliminaciju preostale greške. Omogućuje preciznije postavljanje na konačnu vrijednost, ali zbog njega sustav sporije reagira. Integracijski dio regulatora dodaje se po potrebi, ako želimo i kako greška u stacionarnom stanju nebi postojala. Derivacijski dio regulatora predviđa grešku u budućnosti u odnosu na trenutnu promjenu greške. Koristi se kako bi se ubrzala reakcija sustava na grešku. Ovaj dio je jako osjetljiv te uvodi kašnjenja.

U ovome rješenju koristi se samo proporcionalni dio regulatora jer je pokazao da za potrebe eksperimenta dovoljno dobro prati referencu. S obzirom na velike količine šuma, derivacijski član se isto ne koristi.

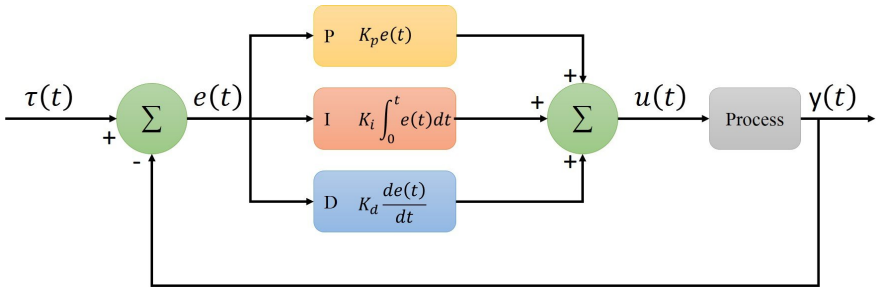

Slika 2.6: Blok dijagram PID kontrolera.

3. Eksperimenti

3.1. Postav eksperimenta

3.1.1. Postavljanje gradiometra

Gradiometar je postavljen točno ispod robota 3.1. To mjesto je najprikladnije i najjednostavnije za postaviti senzor. Za senzor je dizajniran prikladan nastavak kako bi ga se moglo prikvačiti za robota 2.5. U sljedećim eksperimentima se ne koriste magneti iz literature nego neki drugi znatno slabiji te nepoznatog sadržaja. Njih je više spojeno te čine cilindar te stoga imaju jaču snagu skupa nego jedan neodimijski magnet. Rezultati ovih eksperimenata koriste se u softverskoj obradi šuma.

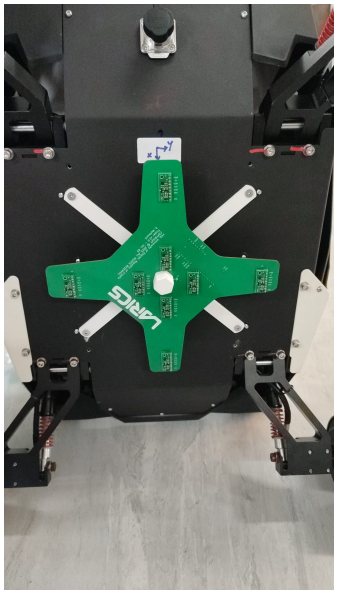

Slika 3.1: Senzor montiran na robotu.

Senzor je jako osjetljiv na promjene te stoga osjetljiv i na šum. Zbog toga su provedena mjerenja kako bi se vidjelo na koji način utječe okolina, elektromotori na kotačima te to usporedili s mjerenjima kada se senzor nalazi blizu magneta. Provedeni eksperimenti su samo vožnja po podu, podizanje robota u zrak i kretnje kotača, stajanje robota uz pomični magnet u zraku i na podu te vožnja preko magneta. Iz tih ekspe-

rimenata zaključeno je da je omjer mjerenja smetnje i mjerenja s magnetom dovoljno velik da senzor može ostati ispod robota i biti korišten za navigaciju.

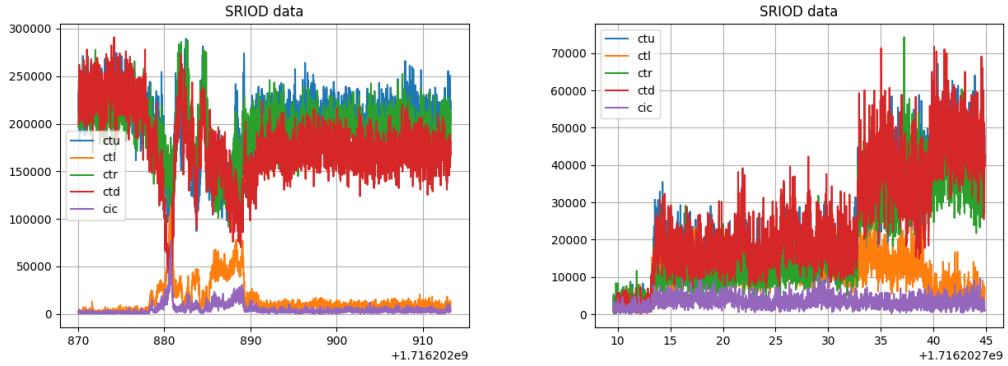

(a) Vožnja po podu. **(b)** Robot u zraku.

Slika 3.2: Mjerenja šuma motora robota.

Na slici 3.2b može se vidjeti da dok je robot u zraku maksimalna razina šuma dolazi na razinu do oko $8{\cdot}10^5$ dok u eksperimentu vožnje po podu 3.2a dolazi i do $3{\cdot}10^6$. Može se zaključiti da bez prisutnosti nekog magnetskog materijala šum neće prijeći razinu $4 \cdot 10^6$ te kasnije u upravljanju sva mjerenja koja su manja od toga se mogu zanemariti. Sljedeći provedeni eksperimenti su napravljeni kako bi se provjerio utjecaj magneta na senzor te kolika je razlika između mjerenog utjecaja magneta i šuma. Robot je bio odignut od poda na dovoljnu razinu da okolina ne utječe na signal te se magnetom prošlo ispod robota oko područja senzora.

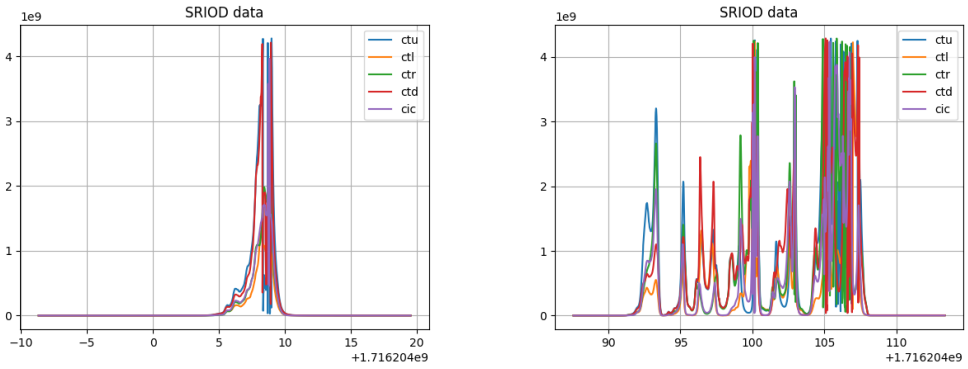

(a) Zrak s magnetom. **(b)** Zrak s pomičnim magnetom.

Slika 3.3: Eksperiment s magnetom i robotom u zraku.

Eksperiment 3.3a proveden je tako da je robot bio statičan podignut u zrak dok se magnet približavao do senzora i nazad. Iz podataka se može vidjeti neka maksimalna vrijednost mjerenja dolazi do razine $4.5 \cdot 10^9$. te da magnet utječe dovoljno jako da

šum nije relevantan. Drugi eksperiment koji je proveden 3.3b je sličan, samo osim približavanja magneta senzoru magnet se pomicao u raznim smjerovima kako bi se vidjelo da magnet ne utječe previše na senzor i da može mjeriti razliku na različitim pozicijama. Ovdje također mjerenja dosežu neku maksimalnu vrijednost od $4.5 \cdot 10^9$ te je zaključeno da senzor može raspoznati poziciju magneta. Idealan omjer šuma 3.1.1 i signala u ovom slučaju iznosi 30.51dB što daje odlične uvjete za navigaciju robotom. Sljedeći eksperimenti koji su provedeni su slični, ali s robotom na podu. Ovi eksperimenti su provedeni kako bi se vidjelo kakav će omjer šuma i signala biti u stvarnom slučaju kada će se robot sam voziti te upravljati mjerenjima dobivenog signala te hoće li šum utjecati na putanju. Kao prvi eksperiment robot se vozi po podu se prelazi preko magneta kako bi se izmjerio signal te vidjela razlika između signala pri vožnji bez magneta ispod robota te sa magnetom. Drugi provedeni eksperiment postavlja robota u stacionarno stanje te se magnet rukom pomiče ispod senzora. Taj eksperiment se provodio kako bi se potvrdili rezultati prethodnog eksperimenta i konačno utvrdio omjer signala i šuma.

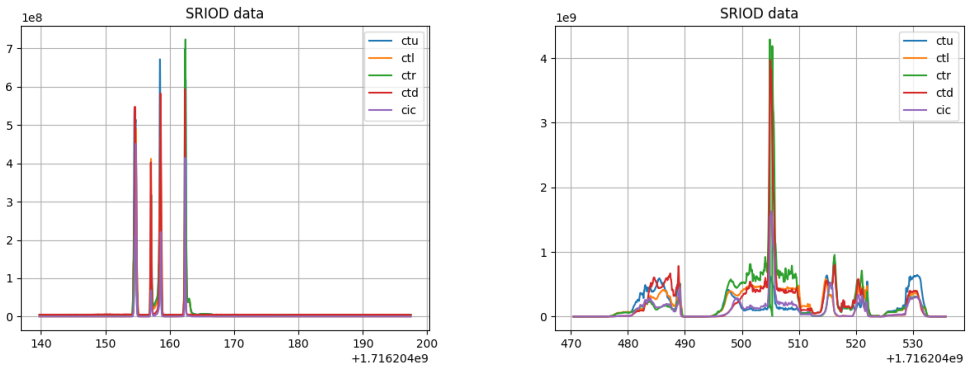

(a) Vožnja preko magneta. **(b)** Približavanje magneta senzoru.

Slika 3.4: Eksperiment s magnetom i robotom na podu.

U eksperimentu vožnje preko magneta 3.4a možemo vidjeti da se vrlo jasno vidi kada robot prelazi preko magneta. U tim trenutcima signal dolazi do razine od $5.5 \cdot 10^8$ do $7.5 \cdot 10^8$ ovisno o tome koliko blizu je bio sam magnet senzoru. Također se ovdje vidi pad signala za red jedne veličine. Iz tih podataka omjer šuma 3.1.1 i signala iznosi 22.11dB za iznos signala $6.5 \cdot 10^8$ što i dalje daje dobar omjer za autonomno upravljanje vozilom. U drugom eksperimentu 3.4b potvrđuje se da je šum zanemariv u odnosu na signal kada se senzor nalazi u blizini magneta.

3.2. ROS i PID

Robot se upravlja preko cmd_vel topica te je za to napisana skripta SriodNavigation.py. Prvo je u ROS implementiran već postojeći kod za dobivanje podataka [6] sa senzora te je za te podatke napisan poseban topic na koji će se slati mjerenja. Podaci se obrađuju u skripti SriodNavigation.py u kojoj je implementiran PID kontroler te se kasnije šalju na cmd_vel. Iz sljedećih eksperimenata zaključeno je da je dovoljan samo proporcionalni dio regulatora.

3.2.1. Staza

Staza 3.5b koju robot treba prijeći napravljena je od neodimijskih magneta zalijepljenih trakom za pod. Svakih 5 cm postavljen je jedan par magneta. Na stazi postoji jedan ravan dio koji se kasnije nastavlja u luk. Za robota je potrebno da taj dio prođe od početka do kraja bez da skrene u nekom drugome smjeru. Samo ravni dio staze koristio se za grubo određivanje proporcionalnog dijela regulatora te se kasnije s dodanim zavijutkom preciznije odredio taj parametar.

(a) Staza sa neodimijskim magnetima. **(b)** Staza s kružnim lukom.

Slika 3.5: Slike staze korištene u eksperimentima.

3.2.2. P regulator

P regulator reagira na trenutna mjerenja te je za njegovo određivanje bitno na koji koliko se brzo robot kreće. Za sporije linearno kretanje potrebna je manja vrijednost, dok za veće brzine i veća vrijednost parametra. Za određivanje K_p prvo je postavljen brzina u pozitivnom x smjeru da bude konstantna. Cmd_vel.x je postavljen na 0.25. Zatim se pri toj brzini određivao K_p. Provedeno je više mjerenja kako bi se najpreciznije odredila vrijednost parametra. Prilikom prikupljanja podataka uzimale su se

vrijednosti koje dolaze direktno sa senzora i s njima računala greška 2.1 te sama greška koju je robot koristio.

Red veličine parametra prvo je određen empirijskim metodama dok robot nije mogao dovoljno dobro slijediti ravnu stazu magneta. Duljina staze je bila postavljena na 65 cm prilikom određivanja parametra te je robot morao moći proći cijelu duljinu staze bez da promijeni smjer kretanja. Red veličine određen je na 10^{-7} te se od toga dalje nastavilo na preciznije određivanje parametra. Na stazu je dodan kružni luk 3.5 koji je omogućavao preciznije određivanje K_p. Testirani parametri su $3 \cdot 10^{-7}$, $3.5 \cdot 10^{-7}$, $4 \cdot 10^{-7}$, $4.5 \cdot 10^{-7}$ i $5 \cdot 10^{-7}$ pri čemu su najbolji rezultati postignuti za vrijednost $4 \cdot 10^{-7}$. U ostalim rezultatima robot bi ili previše ili premalo reagirao na razliku mjerenja sa senzora. Error ili greška se računa po formuli 2.1 te se direktno množi s parametrom K_p. Ta greška nam govori koliko je sam senzor udaljen od izvora magnetskog polja, u našem slučaju magneta na stazi. Na tu grešku robot treba reagirati i ispraviti putanju kako bi se kretao po stazi. Ovdje 3.6 se mogu vidjeti odzivi robota u odnosu na signal sa senzora. Na grafovima 3.6 može se vidjeti greška i za tu grešku izračunata kutna brzina kretanja samog robota. Prilikom dolaska na luk robot ne uspijeva pravovremeno reagirati. To dovodi do izbacivanja robota sa same putanje i neželjenog ponašanja. Za $K_p = 4 \cdot 10^{-7}$ robot uspijeva savladati luk i pratiti stazu zadanu magnetima.

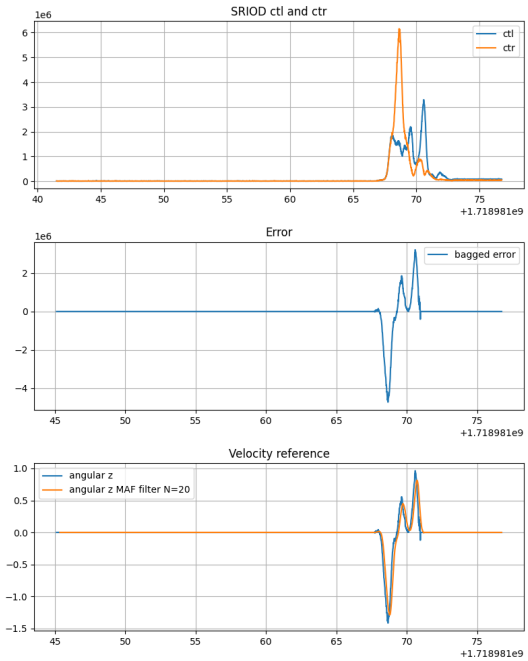

(a) $K_p = 3 \cdot 10^{-7}$.

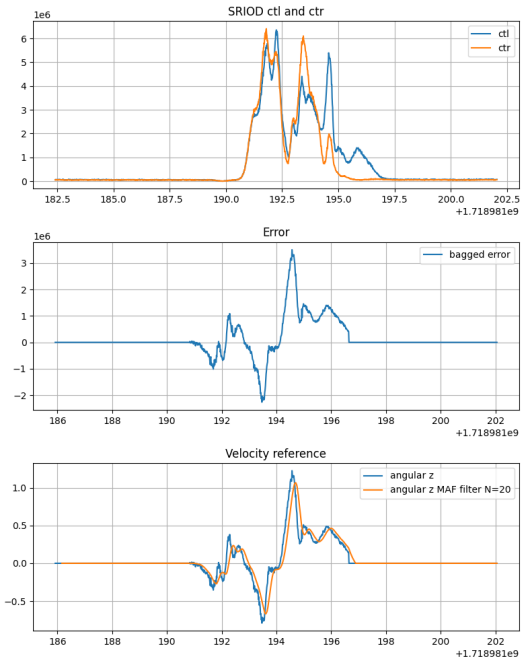

(b) $K_p = 3.5 \cdot 10^{-7}$.

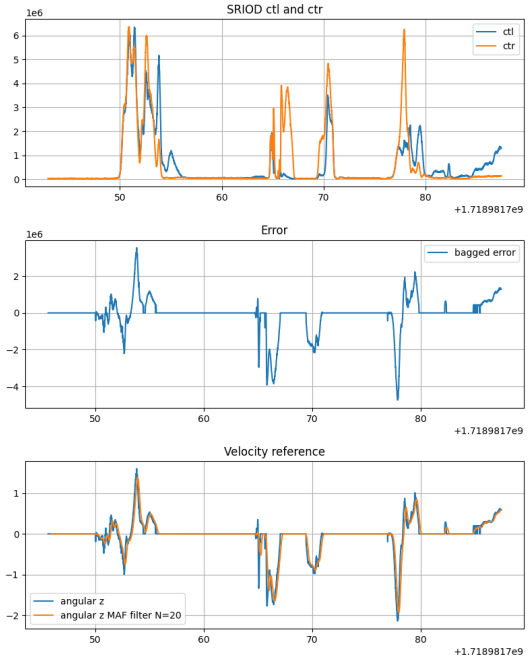

(c) $K_p = 4.5 \cdot 10^{-7}$.

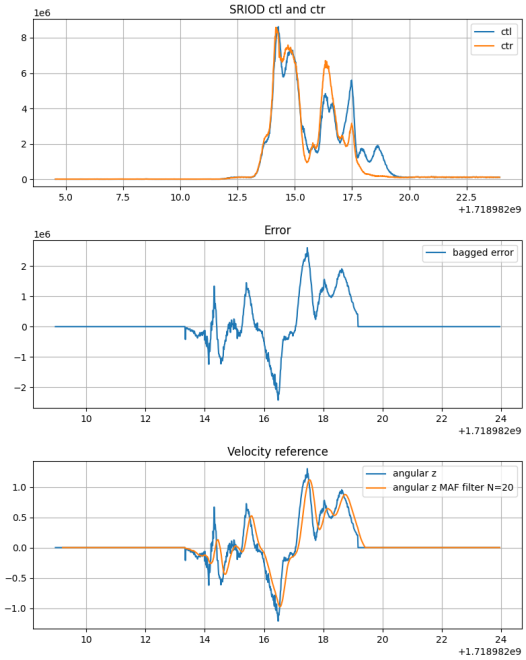

(d) $K_p = 5 \cdot 10^{-7}$.

Slika 3.6: Podaci mjerenja s različitim K_p.

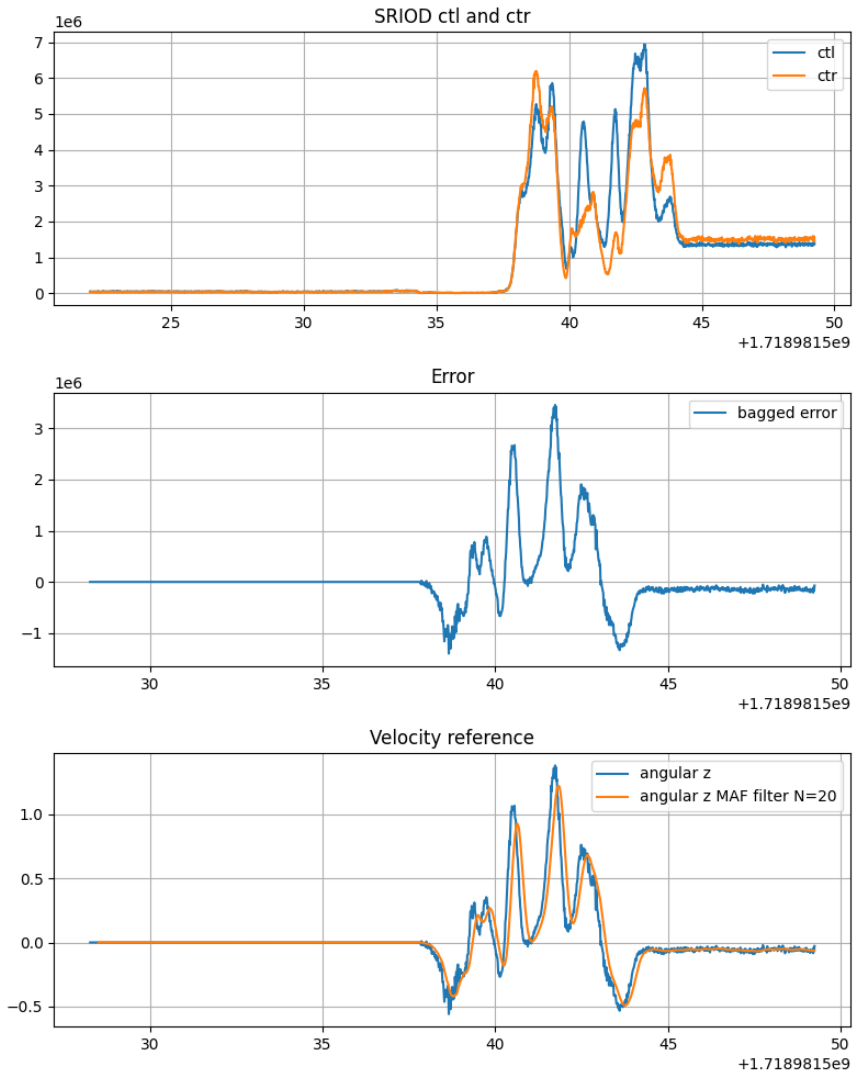

Slika 3.7: $K_p = 4 \cdot 10^{-7}$.

Na grafu 3.7 Error vidi se da se izračunati i stvarni error potpuno poklapaju te da robot može pratiti stazu. S ovom vrijednosti parametra ne treba implementirati integralni dio ni derivacijski dio PID parametra jer robot sam može dovoljno precizno pratiti stazu. Osim PID regulatora implementirani su drugi dodatni filtri koji omogućuju bolje ponašanje robota.

3.2.3. MAF i minimalna vrijednost

Šum u kontroli stvara neželjene vrijednosti koje se propagiraju u konačnici kao grubi i oštri pomaci robota. Kako bi se to uklonilo implemetirano je filtriranje na temelju minimalne vrijednosti koja se empirijski odredila sa grafa 3.2a. Razlog ovakvom ponasanju je da na gradiometru nije svaki senzor jednako otporan na šum. U slučaju ovog

rada, minimalna vrijednost je $4 \cdot 10^6$ 3.1.1. Ako je vrijednost koju senzor manja od zadane onda ju postavlja u 0. U tom slučaju dok se robot ne nalazi blizu magneta kretat će se samo ravno. Rad ovog filtra može se dobro vidjeti an grafu Error za vrijednost proporcionalnog parametra $4.5 \cdot 10^{-7}$ 3.6c gdje u trenutku kada robot skrene sa staze i odmakne se od magneta brzina mu se ruši u 0.

Druga stvar koja je implementirana je MAF (engl. *Moving Average Filter*). Filtar radi tako da zbraja N prošlih vrijednosti i računa njihov prosjek. Tako filtar filtrira šum i omogućava glađi prijelaz brzine i pritom putanje. Zbog toga što zbraja prošle vrijednosti filter u sustav dovodi vremensko kašnjenje. U našem sustavi to vremensko kašnjenje može se vidjeti na grafu Velocity reference 3.7 gdje filter jako zaglađuje prijelaz brzine, ali pritom žrtvuje vrijeme reakcije te dodaje dodatno kašnjenje u sustav.

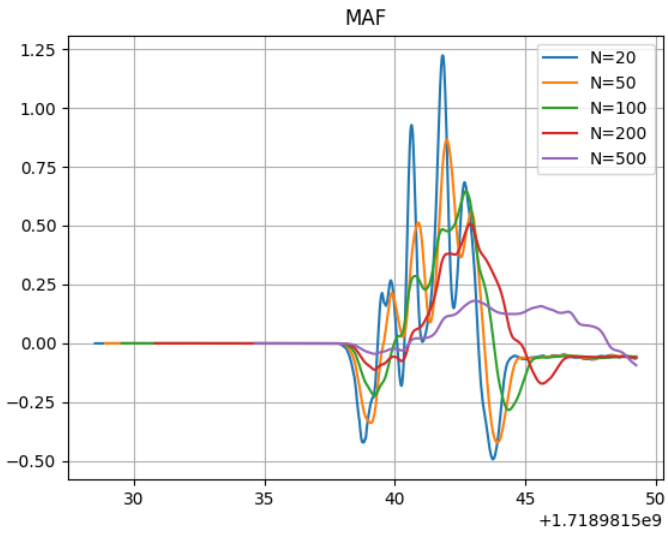

Slika 3.8: MAF filter za $K_p = 4 \cdot 10^{-7}$.

Na grafu 3.8 mogu se vidjeti razni odzivi brzine uz različite veličine za N. Kako se povećava N tako kašnjenje raste, kvaliteta odziva pada te se najbolja veličina za implementaciju čini $N = 20$. Pri tom N kašnjenje nije veliko i šum se dobro filtrira te je odziv i dalje dobar te se može koristiti za uglađenije upravljanje robotom 3.7.

4. Zaključak

Moguće je izvesti praćenje magnetskog otiska uz pomoć gradiometra i povratne veze magnetskim poljem. U ovoj izvedbi korišten je omnidirekcionalan robot te je kontrolirano njegovo rotiranje oko z osi. Brzina prema naprijed je bila konstantna od 0.25 u jedinicama ROS-a. U upravljanju je implementirana granica 3.2.3 koju senzor mora poslati da bi se smatrala valjanom jer je sam podložan šumu. Za samo upravljanje koristi se P regulator. Proporcionalni parametar iznosio je $4 \cdot 10^{-7}$. Pri toj vrijednosti robot je mogao pratiti stazu s lukom na kraju 3.5b. Testirani su i drugi parametri no pri njima robot nije uspio savladati kružni luk. Prilikom obrade podataka implementiran je i MAF 3.8 kako bi se izgladila putanja robota. Takva putanja u odziv dodaje kašnjenje reakcije no filtrira većinu šuma koji mjeri senzor. Najbolja vrijednost za količinu parametara koji ulaze za filtar je 20 3.7. Za tu vrijednost robot i dalje ima dovoljno dobar odziv te se umanjuje komponenta šuma u odzivu što kao rezultat daje fluidnije kretanje robota. Kao daljnje eksperimente potrebno je mjeriti odzive u slučaju da se robota odgurne sa staze te također napraviti dulju stazu. Iz tih podataka potrebno je vidjeti treba li dodatno implementirati integracijski i derivacijski dio kako bi se odziv poboljšao.

5. Sažetak

Za rješavanje problema praćenja magnetskog otiska potreban je gradiometar i mobilni robot. U rješavanju ovog konkretnog problema korišten je omnidirekcionalni robot Scout Mini te gradiometar za mjerenje magnetskog polja magneta. Za stazu se koriste neodimijski magneti zbog njihovog jakog magnetskog polja. Magneti su bili postavljeni u parovima svakih 5 centimetara. Nastavak kojim bi se gradiometar za praćenje polja prikvačio za robota dizajniran je u Autodesk Fusionu te 3D printan. Sama kontrola robota izvedena je u ROS-u P regulatorom. Također je napravljena obrada podataka MAF filterom kako bi se izgladila putanja te potencijalno implementiralo u budućem razvijanju. Njegova implementacija zaglađuje putanju i reakciju te donosi komponentu kašnjenja u odziv.

LITERATURA

[1] Autodesk. Autodesk fusion 360, 2024. URL https://www.autodesk.com/products/fusion-360/overview?term=1-YEAR&tab=subscription&plc=FSN. available: 14.8.2024.

[2] Yougang Bian, Jieyun Ding, Manjiang Hu, Qing Xu, Jianqiang Wang, i Keqiang Li. An advanced lane-keeping assistance system with switchable assistance modes. *IEEE Transactions on Intelligent Transportation Systems*, 21:385–396, 01 2020. doi: 10.1109/TITS.2019.2892533.

[3] Gabrijel Biočić. Github repository, 2024. URL https://github.com/gibonni/sriod-navigation. available: 14.8.2024.

[4] Open Source Robotics Foundation. Robot operating system (ros), 2024. URL https://www.ros.org/. available: 14.8.2024.

[5] Super magnets. Neodimijski magnet, 2024. URL https://elmatis.hr/ProductDetails.aspx?productId=50653. available: 14.8.2024.

[6] Dean Martinović, Jelena Vuletić, Dario Stuhne, Matko Orsag, i Zdenko Kovačić. Object localization by construction of an asymmetric isobody of the magnetic gradient tensor contraction using two identical permanent magnets. *IEEE transactions on magnetics*, 59(4):1–9, 2023.

[7] National Safety Council and University of Iowa. Lane keeping assist - my car does what? https://mycardoeswhat.org/safety-features/lane-keeping-assist/, 2024. Accessed: 2024-08-14.

[8] AgileX Robotics. Scout mini, 2024. URL https://global.agilex.ai/products/scout-mini. available: 14.8.2024.